Raport z przebiegu projektu

Patryk Gładki 20225

Temat: Etykietowanie zdjęć

Wymagania projektowe:

1. Zapoznaj się ze strukturą przykładowego pliku JSON zawierającym informacje o oznaczonych obiektach znajdujących się na skojarzonym z plikiem zdjęciu
2. Uruchom skrypt rysujący wielokąt okalający wybrane obiekty. Tak można ocenić rezultat etykietowania zdjęcia.
3. W Twoim projekcie danymi wejściowymi będzie zbiór obrazów. W ramach projektu dla każdego obrazu powinieneś przygotować plik JSON zawierający etykiety obiektów wybranej klasy (np. osoba, znak drogowy, adres budynku itd.)
4. W rezultacie dla zbioru 300 zdjęć należy stworzyć 300 plików JSON, każdy zawierający zbiór współrzędnych - etykietę obiektów danej klasy znajdujących się na konkretnym zdjęciu.
5. Przykładowy udostępniony plik JSON zawiera ustaloną organizację danych. Zauważ, że nazwane są tam klasy obiektów 'shape' - czyli kształt, jako 'label:'person', 'label':'bottle' itd. Przyjmij taki sam schemat w twoich plikach JSON.

6. W przydzielonym zbiorze zdjęć samodzielnie wyodrębnij klasę obiektów, które będą oznaczane - czyli etykietowane.
7. Do etykietowania możesz wykorzystać dowolne narzędzia programistyczne. Projekt będzie wyżej oceniany jeśli stworzysz i zaprezentujesz własny sposób etykietowania.
8. W raporcie przedstaw analizę jakości uzyskanego rezultatu. Możesz również przedstawić narzędzia (programy, biblioteki), które zostały wykorzystane.

W trakcie prób poradzenia sobie z zadaniem projektowym wykorzystaliśmy następujące biblioteki

Wykorzystane biblioteki:

Tensorflow – biblioteka ułatwiająca tworzenie modeli uczenia maszynowego

opencv-python – biblioteka zawierająca wiele standardowych operacji wykorzystywanych przy przetwarzaniu obrazów

scikit-image – biblioteka zawierająca wiele algorytmów wykorzystywanych do przetwarzania obrazów

pillow – biblioteka wykorzystywana do otwierania i edytowania plików graficznych

pixellib – biblioteka wykorzystywana do segmentacji obrazów i filmów

os – biblioteka zawierająca funkcje wyko0rzystywane do interakcji z systemem operacyjnym

imgaug – biblioteka wykorzystywana w augmentacji obrazów w nauczaniu maszynowym

Dużą inspiracją dla nas była wspomniana na wykładzie metoda segmentacji. Przeszukiwaliśmy sieć w celu znalezienia informacji na ten temat, w celu zaimplementowania takiej metody pod nasze potrzeby

Po okresie poszukiwań udało nam się odnaleźć metodę, która sprawdziła się dla nas bardzo dobrze i nie była aż tak skomplikowana do dostosowania pod nasze potrzeby

I tak zaczęliśmy naszą przygodę z pixellibem, w której naszym celem było sprawienie żeby osiągnął dla nas zmierzony cel

---

Pierwszym sposobem, z którego skorzystaliśmy była segmentacja semantyczna

Modyfikując nieco kod źródłowy by wykorzystać pod nasze potrzeby stworzyliśmy skrypt, który przeszukując zdjęcia w danym folderze oznaczał wszystkie obiekty i odznaczał je osobnym kolorem

Użyty kod:

```
import os
from os import listdir
from PIL import Image
import pixellib
from pixellib.semantic import semantic_segmentation

folder_dir = "C:/Users/zkaak/Documents/proj/zdjecia"
for filename in os.listdir(folder_dir):
    segment_image = semantic_segmentation()
    segment_image.load_ade20k_model("deeplabv3_xception65_ade20k.h5")

    segment_image.segmentAsAde20k("zdjecia/"+filename, output_image_name =filename, overlay = True)
```

Użyty przetrenowany model danych:
deeplabv3_xception_tf_dim_ordering_tf_kernels.h5

Deeplabv3 to już 3 wersja architektury służącej do semantycznej segmentacji znalazła swoje zastosowanie w wykrywaniu wielu obiektów, i głównie służyła na przykład do zmiany tła w trybie rzeczywistym czy znajdywania określonych obiektów

Tasks

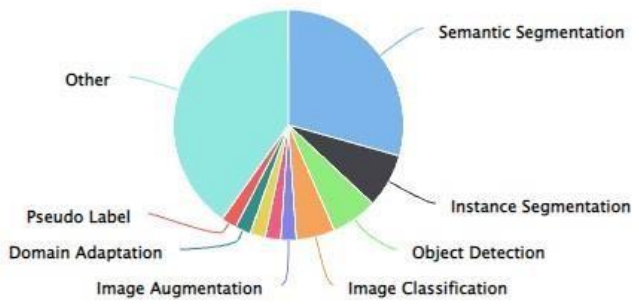

Task	Papers	Share
Semantic Segmentation	27	29.35%
Instance Segmentation	7	7.61%
Object Detection	6	6.52%
Image Classification	5	5.43%
Image Augmentation	2	2.17%
Thermal Image Segmentation	2	2.17%
Medical Image Segmentation	2	2.17%
Domain Adaptation	2	2.17%
Pseudo Label	2	2.17%

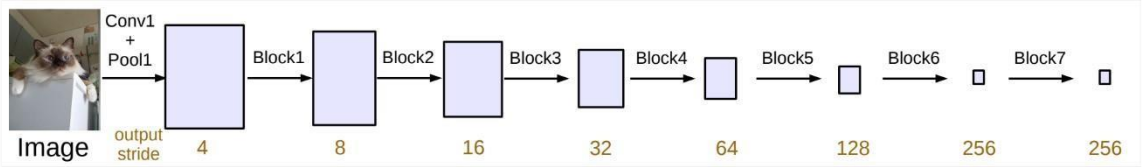

(a) Going deeper without atrous convolution.

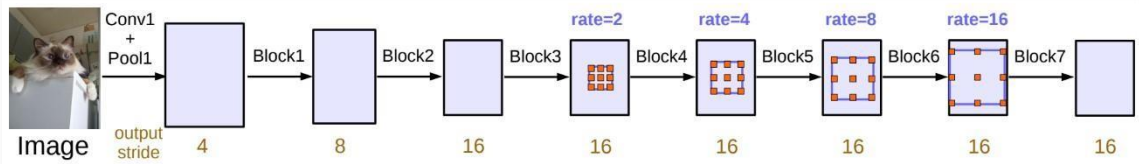

(b) Going deeper with atrous convolution. Atrous convolution with $rate > 1$ is applied after block3 when $output\_stride = 16$.
Figure 3. Cascaded modules without and with atrous convolution.

Otrzymane efekty na zdjęciach testowych:

Program poprawnie odnalazł człowieka oraz oddzielił pozostałe elementy w tle

Program odnalazł jedną osobę, ale niestety omyłkowo zaznaczył też kawałek znaku

Na podanym zdjęciu algorytm się całkowicie rozjechał. Wynika to najprawdopodobniej z tego, że zdjęcie zostało wykonane w nocy, co nie było łatwym zadanie dla programu

Dla pozostałych zdjęć program nie działał aż tak źle, chociaż nie, kiedy miał problemy z zdjęciami, na których ludzie byli w dalekiej odległości

Ze względu na porażkę algorytmu oraz modelu na dużej ilości zdjęć zrezygnowaliśmy z dalszej modyfikacji semantycznej segmentacji, ponieważ nie dostarczyła nam oczekiwanych efektów

Na szczęście pixellib oferował również inne sposoby segmentacji, dzięki czemu byliśmy ruszyć dalej z naszym projektem

---

Wtedy sięgnęliśmy po metodę „Instance segmentation” która okazała się dla nas strzałem w dziesiątkę

Zaledwie 5 linijek kodu wystarczyło żeby samemu oznaczyć zdjęcie, co po modyfikacji pozwoliło nam na przetestowanie tego nowego sposobu z nową maską przetrenowaną w celu wykrywania ludzi

Użyty kod:

```python
import pixellib
from pixellib.instance import instance_segmentation
import os
from os import listdir
from PIL import Image


folder_dir = "C:/Users/zkaak/Documents/proj/zdjecia"
for filename in os.listdir(folder_dir):

    segment_image = instance_segmentation()
    segment_image.load_model("mask_rcnn_cocov2.h5")
    target_classes = segment_image.select_target_classes(person=True)
    segvoutput = segment_image.segmentImage("zdjecia/"+filename,segment_target_classes= target_classes , mask_points_values=True, output_image_name =filename)
```

Użyty przetrenowany model danych: mask_rcnn_cocov2.h5

COCO to zestaw danych do wykrywania obiektów na dużą skalę, segmentacji i tworzenia napisów.

COCO oferuje wiele funkcjonalności i jest stale rozwijany poniżej prezentujemy jego najnowsze osiągniecia i możliwości

Do teraz został przetrenowany na ponad 200 tysiącach zdjęć pod kątem poszukiwania poszczególnych obiektów

Otrzymane efekty na zdjęciach testowych:

Podstawowe zdjęcie testowe nie stanowiło większego wyzwania dla algorytmu nawet pod względem dokładności zaznaczenia

Kolejne zdjęcie testowe również przyniosło lepsze efekty, tym razem nie zaznaczyło drzewa a ponadto wykryło dodatkową osobę w oddali

Kolejne zdjęcie, z którym poprzedni sposób nie poradził sobie kompletnie dla nowego sposobu nie stanowiło większej przeszkody

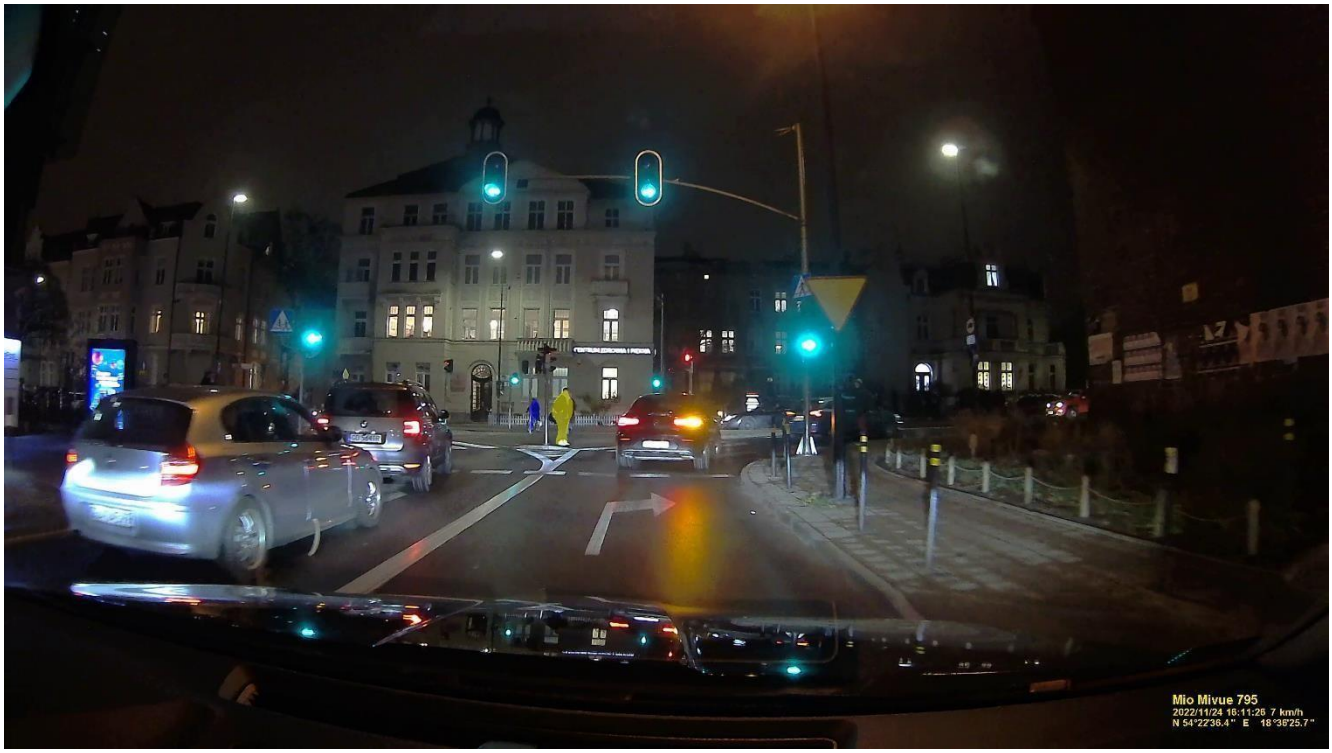

I tak dla kolejnych zdjęć testowych algorytm przynosił lepsze wyniki niż poprzednia wersja. Była to najprawdopodobniej zasługa nowej maski, która była wielokrotnie trenowana jak i samego sposobu algorytmu.


CW 6894E
Mio Mivue 795
2022/12/01 12:54:21
N 54°21'28.5" E 18°35'10.8"


Mio Mivue 795
2022/11/29 11:31:01
N 54°21'34.2" E 18°35'17.8"

Powyższy sposób sprostał naszym oczekiwaniom w zadowalającym stopniu na zestawie testowym. Postanowiliśmy, więc edytując ten algorytm dobrać się do siatki punktów zaznaczonych obiektów w celu wygenerowanie potrzebnych jsonów

Modyfikując kod do działania praktycznie w każdym przypadku otrzymaliśmy następującą wersję:

```python
import pixellib
from pixellib.instance import instance_segmentation
import os
from os import listdir
from PIL import Image



folder_dir = "C:/Users/zkaak/Documents/proj/zdjecia"
for filename in os.listdir(folder_dir):

    segment_image = instance_segmentation()
    segment_image.load_model("mask_rcnn_cocov2.h5")
    target_classes = segment_image.select_target_classes(person=True)
    segvalues, output = segment_image.segmentImage("zdjecia/"+filename,segment_target_classes= target_classes , mask_points_values=True, output_image_name =filename)
    tab=(segvalues['masks'])
    if(len(tab)<=0):
        print("puste")
    else:
        filepath = "zdjecia/"+filename
        img = Image.open(filepath)
        width,height = img.size
        stripped_f = filename.strip(".png")

        with open("json_files/"+stripped_f+".json", 'w') as f:
            f.write('{')
            f.write('\n   "version": "4.0.0",')
            f.write('\n   "flags": {},')
            f.write('\n   "shapes": [')
            li2=0

            for i in tab:
                lz=0
                f.write('\n     {')
                f.write('\n      "label": "person",')
                f.write('\n      "points": [')
                for j in i:
                    for x in j:
                        lz=lz+1
                        f.write('\n        [')
                        f.write('\n         '+str(x[0])+',')
                        f.write('\n         '+str(x[1]))
                        if lz==len(j):
                            f.write('\n        ]')
                        else:
                            f.write('\n        ],')
                f.write('\n     ],')
                f.write('\n     "group_id": null,')
                f.write('\n     "shape_type": "polygon",')
                f.write('\n     "flags": {}')
                li2=li2+1
                if li2==len(tab):
                    f.write('\n     }')
                else:
                    f.write('\n     },')
            f.write('\n   ],')
            f.write('\n   "imagePath": "'+filename+'",')
            f.write('\n   "imageData": null,')
            f.write('\n   "imageHeight": '+str(height)+',')
            f.write('\n   "imageWidth": '+str(width))
            f.write('\n}')
            f.close()
```

Przykładowo wygenerowany json dla 1 osoby:

```
{
    "version": "4.0.0",
    "flags": {},
    "shapes": [
      {
       "label": "person",
       "points": [
         [
          1111,
          889
         ],
         [
          1110,
          890
         ],
```


…….


```
          1148,
          891
         ],
         [
          1147,
          890
         ],
         [
          1137,
          890
         ],
         [
          1136,
          889
         ]
       ],
       "group_id": null,
       "shape_type": "polygon",
       "flags": {}
       }
    ],
    "imagePath": "00e8cabf3daf106507644053a7adbd5a.png",
    "imageData": null,
    "imageHeight": 1600,
    "imageWidth": 2848
}
```


Kiedy skrypt był gotowy przyszła pora na przetestowanie otrzymanego wcześniej w materiałach skryptu generującego oznaczenie wokół zdjęcia

Dokonaliśmy modyfikacji otrzymanego skryptu by oszczędzić pracy ręcznej i nieco zautomatyzować pracę:

Algorytm przegląd folder ze zdjęciami i jeżeli istnieje dla takiego zdjęcia plik json oraz jeszcze nie ma takiego zdjęcia w folderze z zapisanymi konturowanymi zdjęciami zapisuje go tam

```
from PIL import Image, ImageDraw
import json
import os
from os import listdir
from os.path import exists

def read_points(name):
    f = open('json_files/'+name+".json")
    print(f)
    data = json.load(f)
    f.close()
    zbior_punktow = []
    for i in data['shapes']:
        punkty = []
        #print(i["label"])
        for j in i["points"]:
            #print(j)
            punkty.append((j[0], j[1]))
        zbior_punktow.append(punkty)
    return zbior_punktow

def read_img(name):
    img = Image.open("zdjecia_zrobione/"+name+".png")
    w,h = img.size
    print("Format: ", img.format, "Rozmiar: ", img.size, img.mode)
    img1 = ImageDraw.Draw(img)
    xy = read_points(name)
    #img1.polygon(xy,  outline ="red", fill ="#eeeeff")
    for p in xy:
        img1.polygon(p,  outline ="red")
    img.save("zdjecia_konturowane/"+name+".PNG")

folder_dir = "C:/Users/zkaak/Documents/proj/zdjecia_zrobione"
for filename in os.listdir(folder_dir):
    stripped_f = filename.strip(".png")
    file_exists = os.path.exists("zdjecia_konturowane/"+stripped_f+".PNG")
    #if(file_exists!=True):
    read_img(stripped_f)
```

Rezultat działania skryptu:

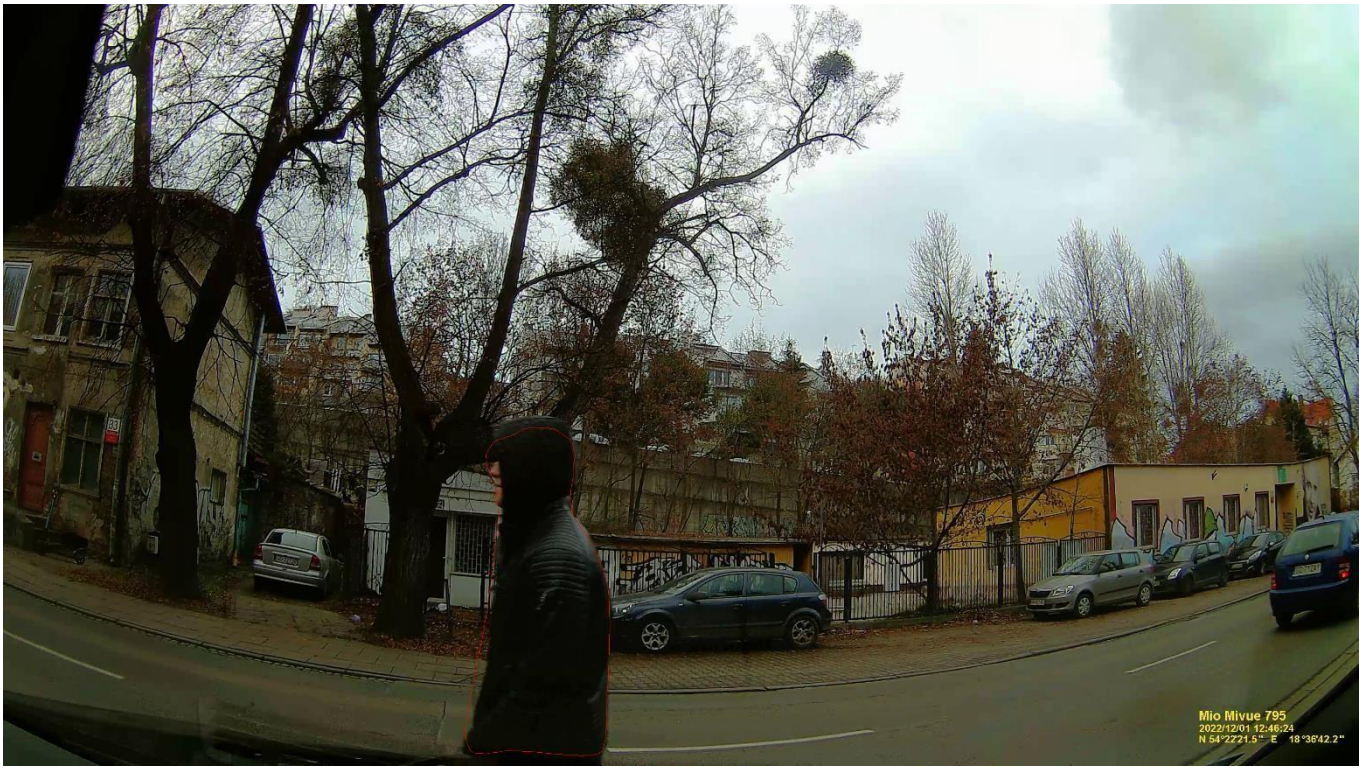
Mio Mivue 795
2022/12/01 12:46:24
N 54°22'21.5" E 18°36'42.2"


Mio Mivue 795
2022/11/29 07:26:26
N 54°22'24.5" E 18°36'48.8"

Mieliśmy już gotowy skrypt do generowania jsonów oraz konturowanych zdjęć przyszła pora na przepuszczenie przez niego całego zestawu 301 wcześniej

przygotowanych zdjęć w celu sprawdzenia dokładności oraz jakości zastosowanego algorytmu w połączeniu z użytą maską

Po przejrzeniu wszystkich wynikowych zdjęć podaliśmy je segregacji w celu wyznaczenia statystyk

Podzieliliśmy je na takie, na których znalazła wszystkie szukane obiekty

Takie, na których znalazło ich za dużo (np. znaki, drzewa, krzewy) Oraz

takie, na których znalazło ich za mało

Z tego podziału otrzymaliśmy następujące wyniki:

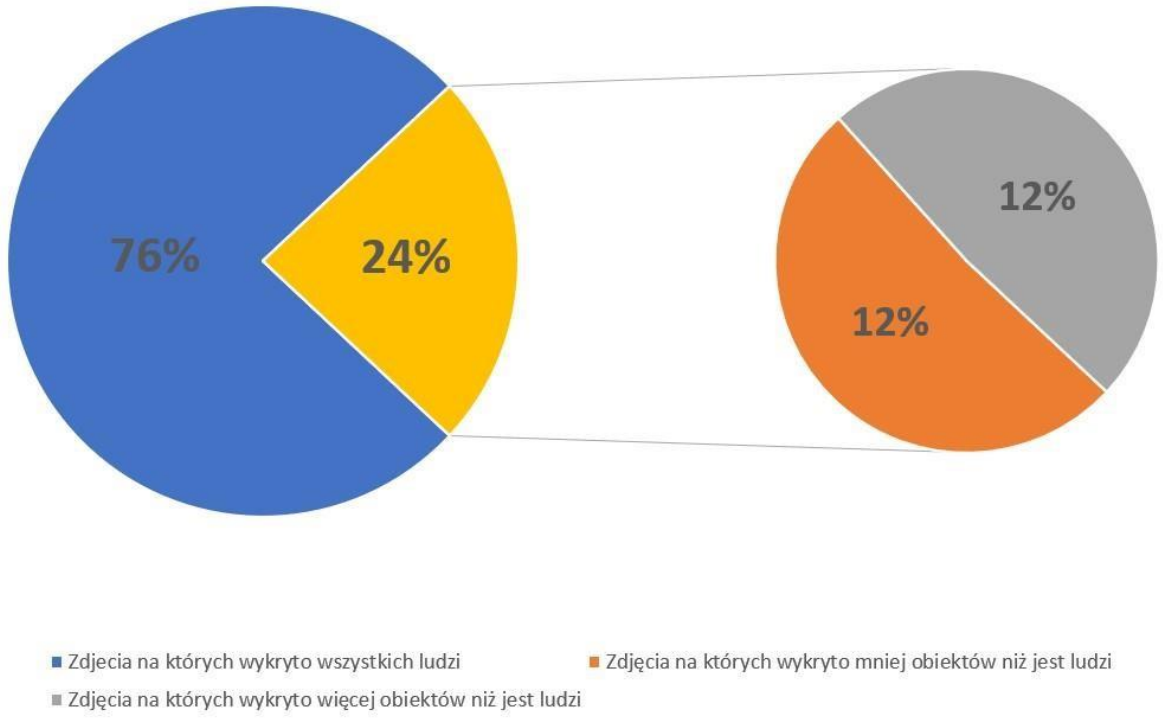

Przykładowe zdjęcia, dla których algorytm znalazł wszystkie osoby:

Jedna osoba w świetle dziennym i nie zbyt dużym ruchu

Matka z córką w oddali stojące w dzień również nie stanowią problemu

Jedna osoba poruszająca się w jednym kierunku w dzień

Przykładowe zdjęcia, dla których algorytm znalazł dodatkowe obiekty nie koniecznie będące osobą:

Na zdjęciu po za ludźmi znalazło dodatkowo ciemne krzaki w tle

Algorytm dodatkowo wykrył rozmyty cień na schodach

Algorytm dodatkowo wykrył ciemny obiekt za szybą stacji

Przykładowe zdjęcia, dla których algorytm nie znalazł wszystkich ludzi:

Jedna z osób w bardzo dalekiej odległości nie została oznaczona

Jedna z osób tuż przed samochodem nie została wykryta

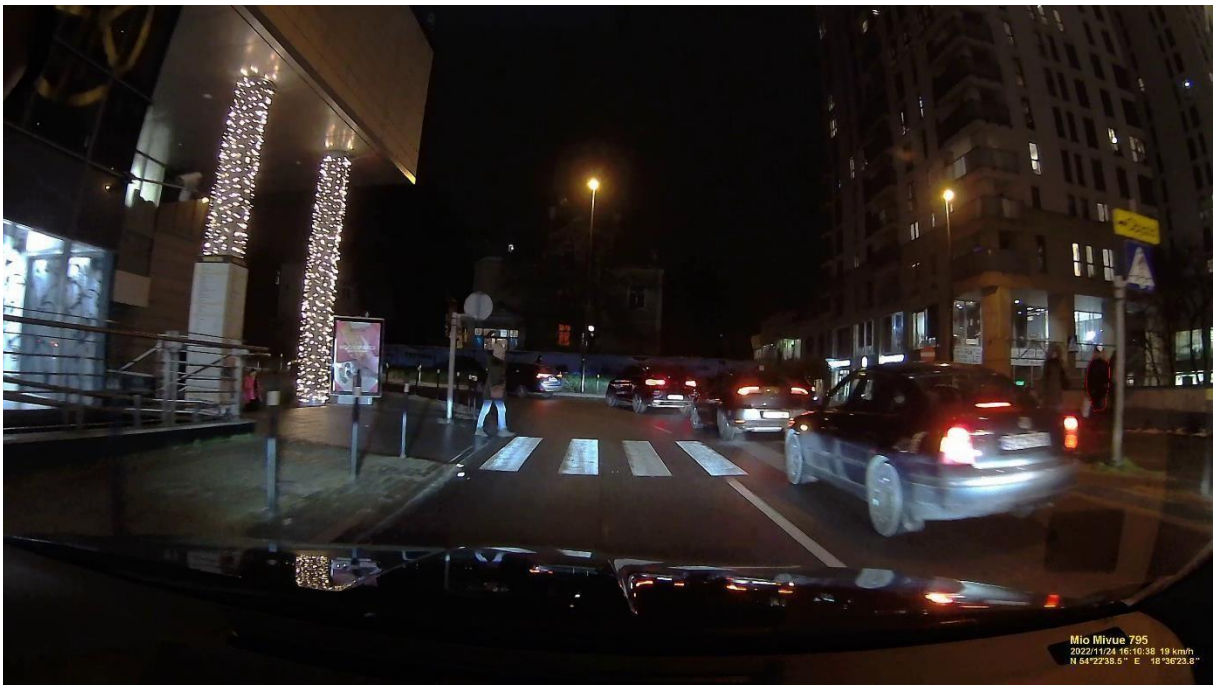

Nie wychwycono osoby trzymającej rower

PODSUMOWANIE

Podsumowując zastosowany przez nas sposób w ostateczności działa w 100% dokładnie dla 76% zdjęć z bazy wybranych daje to dość dobry wynik. Dla 24 % algorytm nie był w stanie znaleźć wszystkich osób lub też znajdywał obiekty niebędące ludźmi. Teraz rozważymy, dlaczego mogło tak być i z czego to wynika

Nasze obserwacje pozwoliły nam zwrócić uwagę na kilka podstawowych czynników wpływających efekty działania algorytmu:

- Po pierwsze i najważniejsze **poza, w jakiej** znajduje się osoba. Algorytm ma z tym nie lada problem, ponieważ człowiek może znajdować się w najróżniejszych pozycjach i przyjmować przeróżne kształty w przeciwieństwie do aut, okien, sygnalizacji, które zazwyczaj są w kilku określonych kształtach.

- Drugim ważnym czynnikiem jest **ruch** ludzie na ulicy zwykle są w ruchu, co często powoduje ich rozmycie na zdjęciach. Prowadzi to do nie wychwycenia ich przez algorytm

- Kolejnym istotnym elementem jest **pora dnia** dla przykładu, kiedy jest jasno ludzie się wyróżniają i dość łatwo jest ich oznaczyć a kiedy jest ciemno ludzie zlewają się z otoczeniem, przez co ciężko jest ich oznaczyć czy odróżnić od otoczenia, przez co algorytm się nie, kiedy myli i oznacza na przykład krzewy czy ciemne cienie
- **Odległość** również wpływa na to czy osoba zostanie wykryta dla przykładu na jednym zdjęciu ten sam człowiek jest wykrywany a gdy odejdzie trochę dalej już nie
- **Zasłonięcie** to znaczy, kiedy osoba nie jest przesłonięta na przykład przez barierkę, samochód czy inną osobę to zostaje w większości przypadków oznaczona prawidłowo, gdy jednak zostanie przesłonięta jest oznaczenie wtedy się zdeformuje w niektórych przypadkach

Podsumowując osiągnęliśmy zamierzony cel i otagowaliśmy wybrane zdjęcia w większości przypadków 100% poprawnie. Co do dokładności zaznaczenia to ma ona margines błędu do kilku milimetrów wynika to głównie z wyżej wymienionych czynników.

Zadanie, które sobie obraliśmy nie należało do najłatwiejszych, ponieważ ludzie nie są najłatwiejszym obiektem do otagowania pomimo tego, że wiele osób czy nawet firm od lat stara się znaleźć idealny sposób na ich oznaczanie, to do dzisiaj nie został on wymyślony, a każdy z dotąd wymyślonych ma swoje plusy i minusy.

Nie należy się jednak podawać, ponieważ cały czas powstają to nowe sposoby, które są rozwijane a także doszkalane są maski, które te wyszukiwanie usprawniają. Chociaż sami nie zdecydowaliśmy się na doszkalanie naszej maski(pomimo istnienia takiej możliwości), ponieważ została ona już wcześniej przeszkolona na setkach tysięcy zdjęć pod kątem znajdywania ludzi, co pozwoliło nam już na niej uzyskać zadowalający efekt a nasze 300 zdjęć nie wiele by do niej wniosło.

Zamiast tego skorzystaliśmy z innych wersji już przeszkolonych wersji wcześniej wspominanych masek, które umieszczamy dodatkowo w plikach projektowych Do projektu dołączamy:

- Folder z 10 zdjęciami testowymi(zdjecia_oznaczone)
- Folder z semantycznym segmentowaniem tych 10 zdjęć(zdjecia_segmantic_deeplab)
- Folder z segmentowaniem instancji tych 10 zdjęć (zdjecia_oznaczone)
- Folder z bazą 301 wybranych zdjęć (zdjecia_zrobione)
- Folder z 301 json'ami (json_files)
- Folder z 301 okonturowanymi zdjęciami (zdjecia_konturowane)
- Oznacznie.ipynb – programy oznaczające zdjęcia na podstawie wygenerowanych json'ów
- Projekt.ipynb – programy generujące zdjęcia i pliki json przy pomocy pixelliba
- Różne maski użyte w celu wyłonienia tej najlepszej pod nasz potrzeby

Bonusowy materiał

Na zakończenie chcieliśmy zaprezentować, że dzisiejsze badania systemów wykrywania ludzi w tak wielkiej firmie, jaką jest TESLA również nie zawsze w 100% dają oczekiwany skutek. Poniżej materiał z nie tak dawnych testów autopilota:

https://www.tiktok.com/@realdanodowd/video/7187030300667464966?is_from_webapp=1&sender_device=pc&web_id=7133619734554510854